

로맨스 스캠 대화 판별을 위한

LLM 과 유사 사례 검색 기반 위험 점수 시스템

공동저자 통합용 기술 논문 초안

1 서론

본 연구는 텍스트 대화의 로맨스 스캠 관련 위험 신호를 분석하기 위해 특화 대규모 언어모델과 유사 사례 검색을 결합하는 프로토타입 구조를 제안한다. 모델의 대화 분석 결과와 검색 사례의 라벨 정보를 각각 수치화하고, 명시적인 결합식과 구간 판정 규칙을 통해 위험 지수와 고정 안내문을 제공하도록 설계한다.

본 연구의 기술적 기여는 다음과 같이 정리한다. 첫째, 로맨스 스캠 대화 판별을 위한 LLM 과 사례 검색 기반 RAG 의 하이브리드 구조를 제시한다. 둘째, 모델 판단과 검색 결과를 서로 분리된 증거원으로 표현한다. 셋째, 방향 증거와 검색 가중치 총량을 명시적인 수식으로 결합하는 Risk Score 구조를 정의한다. 넷째, 생성형 LLM 의 출력과 최종 판정 문구를 분리하고 결정론적 코드가 구간 판정 및 안내문 선택을 수행하도록 한다. 다섯째, 이 구조를 프로토타입으로 연결하여 구현 가능성을 검증하는 것을 연구 범위에 포함한다. 실제 통합 구현의 검증 결과는 [실험 후 작성]한다.

2 기술적 배경 및 관련 연구

2.1 LLM 기반 텍스트 분석

LLM 기반 텍스트 분석은 개별 단어뿐 아니라 발화 간 문맥과 관계를 분류에 활용하는 접근이다. 본 연구에서 특화 LLM 은 친밀감 형성, 금전·투자 요구, 외부 메신저 이동, 감정적 압박 등의 문맥을 분석하여 후속 계산에 필요한 클래스 점수를 제공하는 역할을 맡는다. 구체적인 기반 모델과 특화 학습 방법은 실험 설정에서 확정한다. [관련 문헌 추가 필요]

2.2 사례 검색과 벡터 검색

검색 증강 접근은 외부 자료를 검색하여 모델 또는 의사결정 과정에 활용한다. 본 연구에서 사용하는 RAG 는 대화 embedding 으로 과거 유사 사례를 검색하고, 해당 사례의 라벨과 유사도를 별도 증거로 계산하는 방식이다. 검색 문서를 LLM 의 생성 입력에 추가하는 경로는 현재 구조에 포함되지 않는다. 따라서 기술적 동작은 사례 검색 기반 증거와 모델 증거의 후단 결합으로 설명할 수 있다. [관련 문헌 추가 필요]

Embedding 기반 Vector Search 는 동일 표현 공간에 배치된 query 와 corpus 벡터의 유사도를 이용해 후보를 선택한다. 의미적 유사도는 검색 기준이며 현재 사례의 정답이나 과거 라벨의 적용 가능성을 직접 보장하는 값은 아니다. [관련 문헌 추가 필요]

2.3 점수 기반 의사결정과 하이브리드 구조

학습 모델의 출력과 명시적 점수 계산·판정 규칙을 결합하면 각 단계의 역할을 구분하여 기술할 수 있다. 본 연구에서는 LLM, 사례 검색, 수식 결합, 구간 판정, 고정 출력이 각각 분리된 모듈을 구성한다. 이러한 분리는 계산 과정의 확인을 위한 구조이며, 판별 성능 향상이나 두 증거원의 통계적 독립성을 전제하지 않는다. [관련 문헌 추가 필요]

3 제안 방법

3.1 전체 시스템 구조

전체 시스템은 공통 대화 입력을 특화 LLM 과 RAG 검색 경로에 전달하고, 두 경로에서 얻은 Model Margin 과 RAG Evidence 및 Quality 를 수식 계산 모듈에서 결합한다. 결합 결과를 0~100 의 Risk Score 로 변환한 뒤 LOW, UNKNOWN, HIGH 구간을 판정한다. 마지막 출력 모듈은 해당 구간의 고정 안내문을 선택한다. 그림 1 은 v1 파이프라인의 모듈 관계를 나타낸다.




그림 1 모델 분석과 사례 검색을 분리한 전체 추론 구조

모델 점수 계산, embedding, 벡터 검색, 검색 결과 처리, 수식 계산, 구간 판정 및 출력 생성은 각각 분리된 역할을 갖는다. 수식과 최종 판정은 일반 수치 계산 코드에서 수행하며, LLM 이 최종 위험 점수나 사용자 안내 문구를 직접 생성하지 않는다.

3.2 입력 데이터와 공통 관찰 범위

입력 범위는 복사·붙여넣기 형태의 채팅 기록과 구조화된 messages 를 포함하는 텍스트 대화이다. 분석 입력은 messages 의 각 발화에서 speaker 와 text 를 순서대로 추출한 JSON 배열로 직렬화한다. 발화 순서와 문자열의 공백·줄바꿈을 보존하고, 모델 입력과 검색 query 및 corpus embedding 에 동일한 직렬화 기준을 적용한다. 라벨, 검증 여부, 사건 식별자, 사후 설명은 관리 정보 또는 학습 정답으로 분리한다.

각 tokenizer 를 기준으로 모델과 embedding 의 입력 한도를 모두 검사한다. 모델의 한도에는 고정 분류 지시문과 출력 예약 길이를 포함한다. 한도를 초과하면 입력 오류로 처리하며 자동으로 서로 다른 구간을 잘라 사용하지 않는다. 별도 관찰 구간이 제공되면 양쪽에 같은 구간을 적용한다. 대화 내부의 지시문은 실행 지시가 아닌 분석 대상 데이터로 취급한다.

3.3 특화 LLM 과 Model Evidence

모델 점수 모듈은 SCAM, NON_SCAM, UNKNOWN 순서에 대응하는 정규화 점수 p_S, p_N, p_U 를 반환한다. 각 점수는 유한한 $[0,1]$ 값이고 다음 조건을 만족한다. 이 점수는 모델 내부의 정규화 값이며 통계적으로 보정된 확률로 해석하지 않는다.

$$p_S + p_N + p_U = 1 \quad (1)$$

모델이 logits 를 반환하는 경우에는 v1 에 정의된 안정적 softmax 변환을 적용한다. 클래스별 log-probability 를 사용하려면 세 클래스 전체의 비교 가능한 점수 정의가 필요하며, 다중 토큰 라벨의 첫 토큰만 비교하거나 자연어로 생성된 숫자를 점수로 사용하지 않는다.

$$p_j = \frac{\exp(z_j - z_{\max})}{\sum_k \exp(z_k - z_{\max})}, z_{\max} = \max_k z_k \quad (2)$$

정규화된 세 점수의 합이 0 이거나 1 과의 차이가 10^{-6} 보다 크면 오류로 처리한다. 허용오차 이내의 경우에만 합으로 재정규화한다. Model Margin 또는 Model Evidence 는 다음과 같이 정의한다.

$$M = p_S - p_N \quad (3)$$

M 의 범위는 -1 부터 1 까지이며, 양수는 SCAM 방향, 음수는 NON_SCAM 방향의 증거를 의미한다. 이 값은 3 클래스 argmax 가 아닌 방향 margin 이다. 모델에서 UNKNOWN 이 가장 큰 점수를 갖더라도 최종 UNKNOWN 을 강제하지 않으며, 최종 보류 여부는 3.7 절의 Risk Score 구간으로 결정한다.

3.4 Embedding 과 RAG Retrieval

RAG index 에는 verified 가 참이고 라벨이 SCAM 또는 NON_SCAM 인 사례만 포함한다. UNKNOWN 과 미검증 사례는 검색 증거 및 Quality 계산에서 제외한다. 자격 조건은 후보 검색 전에 적용하고 점수 계산 경계에서도 재확인한다. 빈 라벨이나 미지원 라벨을 NON_SCAM 으로 대체하지 않는다.

Query 와 corpus 는 같은 embedding 모델·버전·차원으로 표현한다. 유한한 영벡터가 아닌 벡터를 L2 정규화하여 cosine similarity c 를 구하고, 수식에 사용하는 similarity 는 다음과 같이 변환한다. 실제 반환값이 cosine distance $d = 1 - c$ 인 경우에는 $c = 1 - d$ 로 복원한다.

$$s = \max(0, c) \quad (4)$$

Cosine 의 허용 범위는 $[-1, 1]$ 이며 경계 밖 10^{-6} 이내의 반올림 오차만 보정한다. 영벡터, NaN/Inf, 명백한 범위 이탈 및 미지원 metric 은 오류로 처리한다. Query 별 min-max 정규화는 사용하지 않는다.

검색은 K_{retrieve} 개의 후보를 확보한 뒤 최소 유사도와 인접 후보 간 gap 을 적용한다. 초기 후보 수는 8 이며, 최종 사용 수의 상한 K_{max} 는 5 이다. 최소 유사도 τ 를 통과하는 후보 집합과 인접 후보 간 gap 은 다음과 같다.

$$\mathcal{C} = \{i | s_i \geq \tau\} \quad (5)$$

$$\Delta_i = s_i - s_{i+1} \quad (6)$$

유사도 내림차순으로 안정 정렬한 후보에서 첫 번째 gap 이 δ 보다 클 때 그 뒤의 결과를 제외한다. 동렬은 검색기가 반환한 입력 순서를 유지하며 gap 이 δ 와 같으면 제외하지 않는다. 선택 개수는 다음과 같이 표현된다.

$$K_{\text{effective}} = \min(K_{\text{threshold}}, K_{\text{gap}}, K_{\text{max}}) \quad (7)$$

여기서 threshold 통과 수가 $K_{\text{threshold}}$, 첫 gap 이전까지의 수가 K_{gap} 이다. Gap 이 없으면 두 수는 같고, 후보가 0 개이면 0 개, 1 개이면 gap 비교 없이 1 개를 선택한다. 그림 2 는 검색 후보에서 최종 증거를 얻는 처리 흐름이다.




그림 2 유사도 필터와 adaptive top-k 를 적용한 검색 증거 처리

3.5 RAG Evidence 와 Quality

선택된 사례의 라벨을 다음과 같이 부호화한다. 아래 합산의 대상은 앞 절에서 최종 선택된 유효 사례이다.

$$y_i = \begin{cases} +1 & \text{SCAM} \\ -1 & \text{NON_SCAM} \end{cases} \quad (8)$$

유사도 가중치는 다음과 같이 계산한다. s_i 가 τ 미만이면 가중치는 0이며, γ 는 유사도에 따른 가중치 곡선을 조절한다.

$$w_i = \left(\frac{s_i - \tau}{1 - \tau} \right)^\gamma, s_i \geq \tau \quad (9)$$

총 가중치 $W = \sum_i w_i$ 가 양수일 때 Signed RAG Evidence R 과 RAG Quality Q 를 계산한다.

$$R = \frac{\sum_i w_i y_i}{\sum_i w_i} \quad (10)$$

$$Q = 1 - \exp\left(-\frac{\sum_i w_i}{\kappa}\right) \quad (11)$$

R 은 -1 부터 1 사이의 방향 증거이며, 상반된 라벨의 가중합이 상쇄되면 0 에 가까워진다. Q 는 가중치 총량의 포화 함수로서 수학적으로 0 이상 1 미만이다. 정답 신뢰도나 독립 사건 수를 추정하는 확률이 아니며, 가중치 총량을 결합식에 반영하는 지수이다. κ 는 포화 속도를 조절한다.

검색 라벨의 가중 일치 정도와 그에 따른 파생 지수는 다음과 같이 계산한다.

$$A = |R|, Q_{\text{eff}} = QA \quad (12)$$

v1에서는 A 와 Q_{eff} 를 내부 진단값으로만 보존한다. 최종 결합 가중치에는 원래의 Q 를 사용하며 Q_{eff} 로 대체하거나 A 를 다시 곱하지 않는다. 선택 결과가 없거나 총 가중치가 0 이면 $R = Q = A = Q_{\text{eff}} = 0$ 으로 두어 나눗셈을 수행하지 않는다.

3.6 Model 과 RAG 의 결합 및 Risk Score

최종 통합 Evidence E 는 모델 기본 가중치 α 와 검색 기본 가중치 β 를 사용하여 다음과 같이 계산한다.

v1의 결합 방식은 Q fusion으로 고정한다.

$$E = \frac{\alpha M + \beta QR}{\alpha + \beta Q} \quad (13)$$

초기값 $\alpha = \beta = 1$ 에서는 다음 식을 사용한다.

$$E = \frac{M + QR}{1 + Q} \quad (14)$$

유효한 정의역에서 E 는 -1 부터 1 사이에 위치한다. 정상적인 검색에서 유효 증거를 얻지 못하여 Q 가 0 이면 E 는 M 과 같아져 Model-only 계산이 된다. 서로 반대되는 증거도 같은 결합식으로 처리하지만, 충돌 자체가 최종 UNKNOWN을 보장하지는 않는다.

결합 Evidence 는 다음 선형 변환으로 Risk Score S 에 대응시킨다.

$$S = 50(1 + E) \quad (15)$$

S 의 범위는 0~100이며, 이를 로맨스 스캠 위험 지수로 표시한다. 이 점수는 실제 사기 발생 확률이나 확률 백분율로 해석하지 않는다.

3.7 구간 판정과 고정 출력

Risk Score 와 최종 클래스는 구분한다. 하한 T_L 과 상한 T_H 를 사용한 판정식은 다음과 같다.

$$\text{Class}(S) = \begin{cases} \text{NON_SCAM} & S < T_L \\ \text{UNKNOWN} & T_L \leq S \leq T_H \\ \text{SCAM} & S > T_H \end{cases} \quad (16)$$

사용자 출력 수준 LOW, UNKNOWN, HIGH 는 각각 위 식의 NON_SCAM, UNKNOWN, SCAM 구간에 대응한다. LOW 는 실제 사건의 정상성을 확정하는 표현이 아니라 해당 구간의 위험 지수 표시이다. 초기 문서의 40 과 60 은 예시 임계값이며, 최종 값은 validation 에서 결정한다.

출력 모듈은 risk_score, level, message, disclaimer 를 구성한다. LOW 에는 위험 신호가 비교적 낮게 탐지되었다는 문구, UNKNOWN 에는 현재 정보만으로 명확한 판단이 어렵다는 문구, HIGH 에는 위험 신호가 높게 탐지되어 추가 확인이 권장된다는 문구를 미리 정의한다. 출력 단계에서 LLM 을 다시 호출하지 않으며 다음 안내 문구를 함께 표시한다.

“LLM 기반 분석 결과는 오류가 있을 수 있으며, 본 결과만으로 실제 사기 여부를 확정할 수 없습니다.”

3.8 내부 로그와 수치 처리

사용자 출력과 별도로 모델의 세 점수 및 M , 검색의 $R \cdot Q \cdot A \cdot Q_{\text{eff}}$ 와 사용 사례, 결합 설정 fusion_mode=q, 최종 점수와 판정 수준을 내부 로그에 기록할 수 있다. 이 분리는 최종 점수만으로 구분하기 어려운 모델·검색의 기여를 연구 및 디버깅 과정에서 확인하기 위한 것이다.

설정은 $0 \leq \tau < 1, \delta \geq 0, \gamma > 0, \kappa > 0, \alpha > 0, \beta \geq 0$ 과 $0 \leq T_L < T_H \leq 100$ 을 만족해야 한다. 후보 수는 $K_{\text{retrieve}} \geq K_{\text{max}} \geq 1$ 인 정수로 제한하고 모든 입력 수치와 설정의 유한성을 확인한다. 작은 총 가중치에서의 소거 오차를 줄이기 위해 Q 는 동일 수식의 구현인 $-\text{expm1}\left(-\frac{w}{\kappa}\right)$ 로 계산하며, 부동소수점 포화로 Q 가 정확히 1 이 되는 경우는 허용한다.

입력·모델·수식의 오류는 정상 위험 점수로 임의 대체하지 않는다. 검색은 성공했지만 유효 증거가 없는 경우의 Model-only 계산과, 검색 시스템의 장애에 대한 대응 정책은 구별한다. 후자의 세부 fallback 정책은 현재 설계에서 후속 확정 사항이다.

4 데이터셋 및 전처리

4.1 데이터 구조와 라벨

데이터는 대화 한 건을 JSON 객체 하나로 표현하는 JSONL 형식을 기준으로 정리한다. 표 1은 v1의 데이터 구조이다. 현재 확보된 실제 데이터 수량, 출처별 구성 및 최종 정제 결과는 [실제 데이터 수량 후 작성]한다.

표 1 대화 데이터의 기본 스키마

필드	구분	정의
conversation_id	기본	각 대화를 구별하는 고유 식별자
case_group_id	기본	동일 사건·가해자 또는 강하게 연결된 사건군의 식별자
label	기본	사건 결과에 대한 SCAM, NON_SCAM, UNKNOWN 라벨
verified	기본	사람이 확인 근거와 주석 기준을 검토·기록했는지 나타내는 불리언
messages	기본	speaker와 text를 포함하는 순서가 있는 발화 배열
scam_stage	선택	제공된 대화에서 관찰되는 단계
risk_factors	선택	제공된 대화에서 관찰되는 위험 요소
evidence	선택	위험 요소에 대응하는 실제 발화 및 발화 위치
reason_summary	선택	관찰 신호와 확인된 사건 결과를 구별한 짧은 설명

SCAM은 확인 근거에 따라 사기로 확인된 사건, NON_SCAM은 확인 근거가 있는 정상 관계·거래의 대화를 의미한다. UNKNOWN은 주어진 자료로 사건 결과를 확정할 수 없는 상태이며 별도의 사건 유형을 뜻하지 않는다. 라벨은 사건 결과를 나타내므로, 이미 결과가 확인된 사건의 초기 대화에 현재 관찰 가능한 위험 신호가 적게 나타날 수 있다. 이때 대화에 없는 금전 요구나 친밀감 형성 속도를 주석으로 추가하지 않는다.

verified=true는 단순한 열람이 아니라 확인 근거와 주석 기준을 사람이 검토하고 기록한 상태를 뜻한다. 검토 후에도 사건 결과를 확정할 수 없다면 UNKNOWN과 verified=true를 함께 사용할 수 있다. LLM의 추측만으로 검증 상태를 참으로 바꾸지 않으며, 확인 근거·출처·기준은 대화 식별자에 연결된 별도 관리 기록으로 둔다. RAG에 사용할 수 있는 라벨 자격은 3.4절의 이진 라벨 조건을 따른다.

4.2 정제와 입력 구성 원칙

정제 과정에서는 발화 순서와 원문을 보존하고 화자 표기를 A, B 등으로 통일한다. 모델이 추론 시 알 수 없는 가해자·피해자 표기를 입력에 추가하지 않으며, 대화를 임의로 요약하거나 원문에 없는 사실을

생성하지 않는다. 위험 요소와 근거 문장은 실제 관찰 내용으로 제한한다. 모델과 검색용 문자열은 3.2 절의 공통 입력 계약에 따라 구성한다.

초기 학습 구성으로는 정상 대화와 스캠 대화의 5:5 비율을 출발점으로 고려하되, 이는 실제 확보된 데이터의 비율이나 운영 분포를 의미하지 않는다. 정상 연애편 아니라 정상 금전·투자·송금·메신저 이동 대화를 포함하여 특정 표현만으로 라벨이 결정되지 않도록 구성하는 것이 설계상의 원칙이다. 실제 적용된 구성과 결과는 [실제 데이터 수령 후 작성]한다.

정확 중복·유사 중복·파생본의 식별 기준, 출처별 원문 형식 변환 및 최종 제외 기준 등 구체적인 정제 절차는 [실제 데이터 수령 후 정제 방법 확정]으로 남긴다. 현재 단계에서는 중복 제거 건수나 최종 라벨 분포를 제시하지 않는다.

4.3 사건 단위 분할과 데이터 누수 방지

동일 대화뿐 아니라 동일 사건의 다른 대화와 부분 대화·번역·의역 등의 파생본이 평가 집합과 학습·검색 자료에 걸쳐 포함되지 않도록 case_group_id 를 활용한다. 파생본은 원본의 사건 그룹과 분할을 따르며, Validation/Test 의 사건은 모델 학습 및 해당 평가용 RAG corpus 와 격리하는 원칙을 적용한다. 그룹이 미확인인 자료를 자동으로 독립 사건으로 간주하지 않는다. Train 과 RAG 의 상호 중복 자체는 평가 누수를 의미하지 않는다.

실제 그룹 연결 결과, 분할 비율과 각 집합의 사건 수는 [실제 데이터 수령 후 작성]한다. 이는 평가를 위한 설계 원칙이며, 현재 데이터에 누수가 존재하거나 이미 제거되었다는 실증 결과를 뜻하지 않는다.

5 실험 설정

5.1 검증 범위와 미확정 구성

실험은 제안된 모듈을 연결한 프로토타입의 기능 수행과, 실제 데이터에 대한 판별 특성을 확인하는 범위로 구성한다. 기능 검증에는 공통 입력 전달, 라벨 자격 필터, 수치 정의역, 유효 검색이 없는 경우의 계산, Q fusion, 구간 판정 및 고정 출력의 일관성을 포함한다. 확인 결과는 [실험 결과 삽입 예정]이다.

사용할 특화 LLM 의 모델명·버전과 학습 방법은 [모델 및 학습 설정 확정 후 작성], embedding 모델·버전과 벡터 검색 구현은 [검색 구현 확정 후 작성], 하드웨어와 실행 환경은 [구현 환경 확정 후 작성]으로 남긴다. 데이터 분할 및 RAG corpus 의 실제 규모는 4 절의 자료 확보 이후 기술한다.

5.2 초기 파라미터와 임계값

표 2 는 v1 에 제시된 초기 설정이며, 실제 실험에서 최적화되었거나 성능이 확인된 값은 아니다. 검색 설정은 RAG 수식 문서의 후보 수와 최종 사용 수를 구분하여 기술하고, 결합식은 Q fusion 으로 고정한다.

표 2 프로토타입의 초기 파라미터

항목	설계상 시작값	의미 및 확정 상태
K_{retrieve}	8	검색 후보 수
K_{max}	5	최종 선택 사례 수의 상한
τ	0.60	최소 유사도 시작값
δ	0.10~0.15	gap 기준의 초기 범위; 의사코드 기본값은 0.12
γ	1.0	유사도 가중치 곡선의 초기값
κ	1.0	Quality 포화 속도의 초기값
α, β	각 1.0	모델 및 검색의 기본 가중치
T_L, T_H	40, 60	설명·초기 실험용 예시; 최종값은 validation 에서 결정
fusion_mode	q	v1 의 고정 결합 방식

최종 임계값과 조정 범위는 validation 에서 선택하고 Test 결과를 재튜닝에 사용하지 않는 원칙을 따른다. 실제 탐색 범위, 선택 횟수와 최종 설정은 [실험 후 작성]한다.

5.3 평가 지표와 비교 항목

v1 은 Precision, Recall, F1 및 False Positive·False Negative 를 평가 후보로 제시한다. 최종 주평가 지표와 산출 방식은 [평가 계획 확정 후 작성]한다. UNKNOWN 출력이 있는 평가에서는 검증된 SCAM/NON_SCAM 정답과 세 판정 결과를 구분한 2×3 판정표를 사용하고, SCAM 을 UNKNOWN 으로 보낸 사례를 전체 SCAM Recall 의 분모에서 제외하지 않는 원칙을 따른다. 보류율, coverage 와 확정 판정만의 오류를 구별하며 정답 UNKNOWN 의 평가는 별도로 정의한다.

모델 단독과 Q fusion 등 비교 항목의 최종 구성, 비교 조건 및 반복 횟수는 [비교 실험 계획 확정 후 작성]한다. Q_{eff} 결합이나 gap 변경은 현재 실행 구조에 포함된 대체 모드로 간주하지 않으며 9 절의 후속 비교 후보로 둔다. 비용 기반 임계값 선택을 적용할 경우의 비용과 최소 coverage 조건도 [평가 계획 확정 후 작성]한다.

6 결과

[실험 후 작성]

7 논의

7.1 모델과 검색 증거의 기여

[실험 결과 분석 후 작성]

7.2 보류 판정과 오류 사례

[실험 결과 분석 후 작성]

7.3 프로토타입 구현 결과의 해석

[실험 결과 분석 후 작성]

8 한계

첫째, 현재 결합식은 명시적인 가중치와 임계값을 사용하는 heuristic 구조이다. 모델의 정규화 점수와 Risk Score 는 실제 정답 확률로 보정되어 있지 않으며, 정규화나 0~100 변환만으로 확률적 해석이 성립하지 않는다.

둘째, 유사 사례의 라벨과 의미 유사도는 현재 사례의 정답을 보장하지 않는다. Q 는 가중치 총량에 의존하므로 사례 중복이나 corpus 의 구성과 구별되는 독립 정보량을 직접 표현하지 못한다. A 는 R 의 절댓값으로 결정되며 한 사례만으로도 1 이 될 수 있다. 이러한 특성만으로 실제 corpus 의 품질이나 오류 수준을 단정하지는 않는다.

셋째, 두 모듈을 분리하더라도 오류의 통계적 독립성은 보장되지 않는다. 방향이 반대되는 증거가 존재해도 가중치와 임계값에 따라 최종 판정이 달라지므로 항상 UNKNOWN 으로 보류되는 구조는 아니다. 또한 M 은 세 클래스 점수를 하나의 방향값으로 요약하므로 모델 UNKNOWN 의 argmax 와 최종 보류가 일치하도록 설계되어 있지 않다.

넷째, 첫 gap 을 기준으로 이후 후보를 제외하는 규칙은 불연속 선택이다. 경계 부근의 작은 유사도 변화가 선택 사례를 바꿀 수 있으며, 고정 top-k 보다 우수하거나 안정적이라는 보장은 현재 수식에서 도출되지 않는다. 실제 영향의 크기는 실험으로 판단해야 한다.

다섯째, 적용 범위는 공통 입력 한도 내의 텍스트 대화이다. 프로필 이미지·딥페이크·멀티모달 판별과 운영 환경의 완전한 장애 대응은 현재 프로토타입의 검증 범위에 포함되지 않는다. 최종 점수만으로 정보 부족과 증거 충돌 등 내부 상태를 모두 복원할 수 없다는 점도 점수 요약의 해석상 한계이다.

9 향후 연구

후속 연구에서는 더 큰 실제 데이터셋과 다양한 사건·출처를 활용하여 일반화 가능성을 검증하고, 초기 대화와 스캠 표현에 유사한 정상 대화에 대한 특성을 분석할 수 있다. 실제 사용자 환경에서의 안내 이해도와 활용 가능성도 별도 평가 대상이다. 해당 검증을 현재 시스템의 완료된 기능이나 성능으로 간주하지 않는다.

검색 측면에서는 embedding 모델과 corpus 구성에 따른 차이, gap 유무와 작은 유사도 변화에 대한 민감도를 비교할 수 있다. 중복 통제, 사건당 사례 수 제한, 출처·군집 다양성, 클래스 비율 보정 등은 실제 자료에서의 순효과를 확인한 뒤 선택할 후보이다. 현재 v1의 필수 처리나 확정된 추가 기능으로 두지 않는다.

결합과 출력 측면에서는 Q 와 Q_{eff} 를 사용하는 방식의 차이, 모델 점수의 scaling 및 calibration 필요성을 검토할 수 있다. Q_{eff} 를 결합에 사용할 때의 추가 감쇠와 비단조성은 그 대안을 평가할 때 다룰 성질이며, 현재 Q fusion의 가중치는 Q 이다. 확률 출력을 연구하려면 별도의 calibration 목표와 검증이 필요하다.

운영 적용을 확대하는 단계에서는 검색 장애 시 fallback 정책, 더 상세한 결과 이유 표현과 로그, 파라미터 선택의 민감도를 구체화할 수 있다. 이러한 항목은 설계 검토에서 제기된 후속 개선 후보로 두며 현재 프로토타입의 기능 범위를 확장하는 전제로 삼지 않는다.

10 결론

본 연구는 로맨스 스캠 텍스트 대화를 대상으로 특화 LLM의 Model Evidence와 유사 사례 검색의 RAG Evidence 및 Quality를 결합하는 프로토타입 구조를 제안한다. Q fusion에 따른 통합 Evidence를 Risk Score로 변환하고, 결정론적 구간 판정과 고정 안내문 선택을 통해 최종 출력을 구성한다. 데이터 라벨과 검증 상태, 공통 입력 범위, 수치 정의역 및 평가 데이터의 격리 원칙을 함께 기술하였다. 후속 단계에서는 이 구조의 통합 구현 가능성과 실제 판별 특성을 검증하며, 실험에 근거한 결론은 [실험 후 작성]한다.

공동저자 참고용 설계 근거

설계 기준은 v1 문서 4종이다. Dataset Guide의 §3~4·8~9는 데이터와 입력 계약, Inference Pipeline의 §2~17·28~29는 모듈 구조와 출력·평가 원칙, RAG Retrieval Formula의 §2~16·20~23은 검색 수식과 처리 조건, Risk Scoring Formula의 §3~16·19~21은 모델 증거·결합·판정식의 근거이다. Critical Design Review는 v1에서 보존한 연구 한계와 향후 개선 후보를 구분하는 보조 자료로 사용한다. 외부 관련 연구의 서지정보는 본문의 [관련 문헌 추가 필요] 위치에 추후 보완한다.