


V4 기술자료를 쉽게 읽는 안내서

대화 분석과 사례 검색을 어떻게 합치는지
2026년 10월 6일 최종 구성

1 대화를 두 경로로 읽습니다

한쪽에서는 LLM이 대화의 문맥을 읽고, 다른 쪽에서는 RAG가 비슷한 과거 사례를 찾습니다. 마지막에 두 결과를 숫자로 합칩니다.




LLM은 대화를 읽는 분석가, RAG는 라벨이 붙은 사례 노트라고 생각하면 됩니다. 사례 노트의 내용이 현재 대화와 가깝다면 더 참고하고, 멀다면 덜 참고합니다.

검색 사례를 LLM에게 다시 읽히는 방식은 아닙니다. LLM과 검색이 각각 만든 점수를 나중에 결합합니다. 최종 모델은 V3에서 학습한 특화 E2B를 그대로 사용합니다.

위험 지수 80은 실제 사기 확률 80%라는 뜻이 아닙니다. LOW도 안전 확정이 아니라 이 계산에서 낮은 위험 쪽이라는 뜻입니다.

2 3차원 데이터셋과 검색은 다릅니다

X와 Y는 대화 표현이 비슷한 정도를 나타내는 위치입니다. 사람이 정한 주제 이름이나 행동 점수 그 자체가 아니라, 학습 사례의 표현에서 만들어진 두 숫자입니다.



그림은 최종 RAG 226건의 좌표입니다. 빨간 점은 SCAM, 파란 점은 NON-SCAM입니다. 오른쪽에서는 같은 X와 Y에 라벨의 높이 Z를 붙였습니다.

Z=1이면 SCAM, Z=0이면 NON-SCAM으로 표시합니다. 사례를 비교하기 편하게 위아래로 나눈 것입니다. 하지만 새 대화는 정답을 모르므로 이 Z를 검색에 넣을 수 없습니다.

그래서 실제 검색은 X와 Y만으로 가까운 사례를 찾습니다. 찾은 다음 그 사례들의 라벨을 참고합니다. **3차원 지도 자체 때문에 성능이 좋아진 것은 아닙니다.**

RAG에는 학습 구간의 사례 226건만 있습니다. SCAM 113건과 NON-SCAM 113건입니다. 테스트 대화와 변형의 부모 사례는 넣지 않았습니다.

3 가까운 사례에 따라 참고량을 바꿉니다

검색은 먼저 후보 8건을 찾고, 같은 사건의 중복을 빼서 **최대 5건만 최종 참고**합니다. 더 가까운 사례의 라벨에 더 큰 투표 무게를 줍니다.

RAG 점수 R은 이웃이 사기 쪽인지 정상 쪽인지를 나타냅니다. **거리 가치 q**는 이웃이 얼마나 가까운지를 나타냅니다. 둘은 다른 값입니다. 가까운 사례라도 라벨이나 적용 문맥이 잘못되면 판정도 틀릴 수 있습니다.

q는 0부터 1까지입니다. q=0이면 검색을 반영하지 않습니다. 가까워질수록 검색의 반영량을 키우지만, 검색 비중은 최대 70%로 제한합니다.

65%는 고정 LLM 비율이 아닙니다. q=1일 때 LLM의 극단적인 점수 차이를 65% 크기로 줄이는 설정입니다. q=0이면 LLM 점수 차이를 그대로 둡니다.

기호	쉬운 뜻
M	LLM의 사기 쪽과 정상 쪽 점수 차이
R	가까운 사례들의 라벨 투표
q	검색 이웃이 가까운 정도
w	최종 계산에 넣는 검색 비중
risk	결합 결과를 0~100으로 바꾼 위험 지수

LOW는 40 미만, HIGH는 60 초과입니다. 40부터 60까지는 UNKNOWN으로 보류합니다. 정보가 부족한 LOW를 별도로 표시하는 기능은 아직 구현되지 않았습니다.

4 숫자 예제로 보면 이렇게 됩니다

아래는 설명을 위한 가상 숫자입니다. LLM이 사기 쪽으로 가장 강하게 답해 $M=1$ 이라고 가정합니다. 실제 테스트 점수를 제시한 표는 다음 페이지에 있습니다.

검색 상황	q와 R	최종 지수와 판정
쓸 만한 가까운 근거가 없음	$q=0$ $R=-1$	100.00 HIGH
가까운 사례도 사기 쪽	$q=0.6$ $R=0.8$	89.80 HIGH
가까운 사례는 정상 쪽	$q=0.6$ $R=-0.8$	41.80 UNKNOWN
가장 가까운 근거가 정상 쪽	$q=1$ $R=-1$	24.75 LOW

$q=0.6$ 인 경우를 따라가 보겠습니다. LLM의 점수 차이 1은 **0.79로 완화**되고, 검색 비중은 **0.6**이 됩니다. 검색이 사기 쪽 $R=0.8$ 이면 두 결과를 합친 값은 0.796이고, 이를 0~100으로 바꾸면 89.8입니다.

반대로 검색이 정상 쪽이면 강한 LLM 판정을 보류하거나 뒤집을 수도 있습니다. **항상 RAG를 더 믿는 방식도, 항상 LLM을 더 믿는 방식도 아닙니다.** 거리와 두 점수가 함께 결과를 정합니다.

가까운 정도는 믿을 만한 정도를 완벽히 대신하지 못합니다. 현재의 65%, 상한 70%, 거리 배율 8은 최종 프로토타입에서 고정한 값이며 최적값으로 검증된 것은 아닙니다.

5 실제 결과에서 확인한 것과 남은 것

두 모델을 같은 대화로 새로 실행했습니다. 원본 테스트는 176건, 변형 테스트는 80건이며 둘 다 SCAM과 NON-SCAM이 1:1입니다. UNKNOWN은 오답에 포함했습니다.

구성	원본	변형	합산
원본 E2B 단독	67.05%	76.25%	69.92%
원본 E2B + RAG	82.39%	81.25%	82.03%
특화 LLM 단독	100.00%	97.50%	99.22%
특화 LLM + RAG	100.00%	97.50%	99.22%
RAG 단독	93.75%	90.00%	92.58%

원본 모델에서는 오류 31건을 교정했고, 맞던 답을 틀린 답으로 바꾸지 않았습니다. 특화 모델에서는 판정이 그대로였으므로 RAG가 정확도를 더 올렸다는 결과는 아닙니다.

100%가 나온 원본 테스트도 이미 후보 탐색에 사용한 데이터입니다. 변형 라벨은 미검증이며 같은 부모 사례에서 만든 대화끼리 서로 비슷합니다. 실제 새로운 대화에서 완벽하게 작동한다고 결론 내릴 수 없습니다.

원본 모델과의 결합은 RAG 단독보다 낮고, 특화 모델의 극단적 점수와 정상 대화 오류 2건도 남았습니다. D03 데이터를 늘릴수록 정확도가 계속 오른다는 검증도 아직 없습니다.

자세한 계산과 실행 방법은 같은 폴더의 기술 명세 DOCX를, 연구 결과와 해석은 V4/paper의 논문 DOCX를 참고하세요.